



هدف از فاز سوم پروژه پیاده سازی الگوریتم های خوشه بندی و یک خزنده برای واکنشی اطلاعات مقالات از سایت Microsoft Academic است. در بخش اول این فاز الگوریتم های خوشه بندی را برای یک مجموعه داده ی فارسی پیاده سازی می کنید و خوشه های به دست آمده را در خروجی برمی گردانید. در بخش دوم نیز یک خزنده برای واکنشی اطلاعات مقالات از سایت Microsoft Academic پیاده سازی می کنید و در آخرین بخش PageRank را برای مقالات واکنشی شده محاسبه می کنید.

بخش ۱. خوشه بندی (۵۰ نمره)

در بخش اول باید برای یک مجموعه داده به زبان فارسی، چند الگوریتم خوشه بندی را پیاده سازی کنید. مجموعه داده انتخابی شامل اطلاعات یک مجموعه اخبار در قالب یک فایل json است. در این دادگان، اطلاعات زیر برای هر خبر موجود است:

- title: عنوان خبر
- summary: خلاصه متن خبر
- link: لینک به خبر در وبسایت
- tags: دسته بندی خبر. به فرمت «دسته اصلی < دسته فرعی». مثلاً: «دانش < پزشکی»

برای تبدیل متون اخبار به فضای برداری باید یک بار از طریق TF-IDF و یک بار از Word2vec استفاده کنید. توجه کنید که برای هر دو روش می توانید از توابع و کتابخانه های آماده استفاده کنید. ضمناً استفاده از کتابخانه همضم برای پیش پردازش متون توصیه می شود. الگوریتم های خوشه بندی که باید پیاده سازی شوند نیز عبارت هستند از:

۱. K-means

۲. Gaussian Mixture Model

۳. Hierarchical clustering

توجه: انتخاب تمامی پارامترهای الگوریتم های بالا برعهده ی خودتان است. نحوه انتخاب بهترین عدد برای تعداد خوشه ها و مقادیر سایر پارامترهایی که انتخاب می کنید را در گزارش بیاورید. برای پیاده سازی الگوریتم های خوشه بندی نیز می توانید از توابع و کتابخانه های آماده استفاده کنید. به ازای هر زوج از روش های تبدیل به فضای برداری و الگوریتم خوشه بندی یک فایل csv در خروجی داشته باشید (مجموعاً ۶ فایل) که نتیجه ی خوشه بندی الگوریتم شما است. این فایل ها باید دو ستون داشته باشند: ستون اول لینک خبر و ستون دوم شماره ی خوشه برای آن خبر را قرار دهید. همچنین در گزارش خود تعدادی نمودار از نتایج خوشه بندی های خود (در قالب نمودار دوبعدی یا دندروگرام و یا هر نمودار جالب دیگری) ارائه کرده و در چند سطر به صورت مختصر مشاهدات خود به همراه توضیحاتی ارائه دهید. همچنین حداقل ۲ معیار ارزیابی خوشه بندی را به ازای هر بار خوشه بندی، در گزارش بیاورید. در حین ارزیابی، از دسته بندی اصلی اخبار به عنوان ground truth استفاده کنید.

بارمبندی

بارمبندی این بخش قطعی نیست. بر حسب امتیازهایی که خوشه‌بندی‌های شما به دست می‌دهند نمره‌تان تعیین می‌گردد.

بخش ۲. پیاده‌سازی خزنده، واکشی اطلاعات مقالات (۴۰ نمره)

در این بخش قصد داریم تا برای سایت Microsoft Academic یک خزنده پیاده‌سازی کرده و با استفاده از آن اطلاعات تعدادی مقاله را واکشی کنیم.

اطلاعاتی که از هر مقاله باید جمع‌آوری شوند عبارت هستند از:

۱. عنوان مقاله

۲. چکیده‌ی مقاله

۳. سال انتشار مقاله

۴. تمامی نویسندگان مقاله

۵. ارجاعات مقاله. توجه کنید که تنها ۱۰ ارجاع اول که در صفحه‌ی مقاله در سایت Microsoft Academic قرار دارد کافی است و نیازی به واکشی تمامی ارجاعات نیست.

خزنده برای آغاز کار باید از چند مقاله‌ای که در فایل start.txt وجود دارند و در صف خزش قرار می‌گیرند شروع کرده و ۵۰۰۰ مقاله (تعداد کل مقالات به عنوان پارامتر ورودی داده می‌شود) را ذخیره نماید. همچنین آدرس ۱۰ مقاله‌ی ابتدایی در لیست ارجاعات مقاله‌ی کنونی به صف خزش خزنده اضافه می‌شود. توجه نمایید که برخی مقالات دارای چند نسخه منتشر شده در وبسایت‌های مختلف هستند و یکی از این نسخه‌ها باید ذخیره شود. هیچ مقاله‌ای نباید بیش از یک بار ذخیره شود. اگر لیست ارجاعات یک مقاله کمتر از ۱۰ مورد باشد ایرادی ندارد. همچنین برخی از ارجاعات به صورت لینک نیستند که می‌توانید از آن‌ها چشم‌پوشی کنید.

یک نمونه فایل json از اطلاعات ذخیره شده در فایل sample.json قرار دارد. برای ذخیره‌سازی اطلاعات مقاله‌ها مشابه این فایل نمونه اقدام نمایید. توجه کنید که برای خزش سایت Microsoft Academic شاید نیاز باشد تا بین درخواست‌های خود تاخیر (delay) بیاندازید.

بارمبندی

۱. پیاده‌سازی خزنده (۳۰ نمره)

۲. ذخیره‌ی اطلاعات مقاله‌های به فرمت json و بررسی اولیه اطلاعات استخراج شده (۲۰ نمره)

بخش ۳. PageRank (۱۰ نمره)

در آخرین بخش الگوریتم PageRank را بر روی مقالات واکشی‌شده اجرا کرده و نتایج آن را به دست می‌آوریم. توجه کنید که اگر مقاله‌ی A به مقاله‌ی B ارجاع (reference) داشته باشد، آنگاه پیوندی (link) از مقاله‌ی A به مقاله‌ی B در نظر می‌گیریم. برای این منظور مقدار α مورد نیاز در ورودی گرفته می‌شود و سپس معیار PageRank برای تمامی مقالات محاسبه شده و در خروجی چاپ می‌شود. برای این بخش می‌توانید از ابزارهای آماده استفاده کنید.

بارمبندی

۱. محاسبه‌ی معیار PageRank برای مقالات واکنشی‌شده و گزارش مقالات با بالاترین رنک (۱۰ نمره)

بخش ۴. نکات

۱. امکان تغییر بارم‌بندی وجود دارد.

۲. نوشتن گزارش فراموش نشود. به قوانین کلاس و پروژه که در پیاثرا قرار گرفته است رجوع کنید.